

Aldo Richard Santillán Echevarría

Software Solutions Architect and Artificial Intelligence Engineer

Lima, Lima, PE

richard.24.se@gmail.com | +51 948881161 | fausto.app | LinkedIn



Acerca de

Systems Engineer con +10 años de experiencia, especializado en backend de alto rendimiento y arquitectura de IA Generativa / Sistemas Multi-Agente. Enfoque en 'High-Performance Python' para escalar aplicaciones mediante optimización de algoritmos, gestión de memoria y concurrencia (AsyncIO), maximizando eficiencia de infraestructura. Experiencia en llevar soluciones de IA (LangGraph, RAG, LLMs) a producción, aplicando ingeniería de software robusta (SOLID, Clean Architecture, TDD) y prácticas DevOps (CI/CD, Orquestación) para crear sistemas escalables y eficientes.

Experiencia Laboral

Globant (Cliente: Disney Parks)

2024 - Presente

AI Software Engineer / Software Designer

Liderazgo técnico en 'Yondu', plataforma centralizada de IA Generativa para +15 equipos. Diseño de arquitecturas A2A (Agent-to-Agent), sistemas RAG empresariales y pipelines de ML sobre Azure OpenAI, Vertex AI y Claude. Runtime de inferencia ultra-eficiente con concurrencia masiva non-blocking. Definición de estándares de arquitectura y patrones de diseño adoptados por múltiples squads. Mentoría técnica a desarrolladores junior/mid. Participación en decisiones de arquitectura de la plataforma. Propuesta de mejoras en arquitectura y patrones de diseño. Code reviews de componentes críticos.

- Logré procesar 10K+ requests/segundo manteniendo la infraestructura al mínimo, reescribiendo el núcleo síncrono a una arquitectura 100% Non-Blocking con Python `asyncio` y `uvloop`.
- Diseñé un orquestador de agentes con LangGraph optimizado para reutilizar contextos, reduciendo el consumo de tokens y latencia sin necesidad de servidores adicionales.
- Implementé RAG con algoritmos de búsqueda vectoriales optimizados en código, mejorando la precisión al 92% sin depender de servicios de búsqueda costosos.
- Reduje la huella de memoria de los servicios de inferencia en un 60% mediante profiling profundo (cProfile, memray) y optimización de estructuras de datos.
- Evité costos de escalado vertical (más RAM/CPU) implementando estrategias de gestión de memoria y generadores (lazy evaluation) para procesar payloads masivos de RAG.
- Detecté y resolví anomalías y bugs críticos pre-producción que pasaban desapercibidos.

Globant (Cliente: Vastas)

2023 - 2024

Senior Python Engineer (Performance Specialist)

Modernización de sistemas financieros en empresa de pagos. Migración de procesos core de Java a Python usando Dataflow y GCP. Creación de DAGs en Airflow para orquestación de pipelines. Liderazgo en mejores prácticas de Python para optimización de procesos y código. Diseño de flujos de procesamiento de datos eficientes.

- Reduje la latencia de APIs críticas de 1500ms a 120ms puramente a través de optimización de código (algoritmos más eficientes y eliminación de cuellos de botella en I/O).
- Refactoricé servicios monolíticos para usar concurrencia real, permitiendo manejar 40x más tráfico con los mismos recursos de hardware (CPU/RAM).
- Solucioné 'memory leaks' críticos en procesos de larga duración que obligaban a reiniciar servidores diariamente, garantizando estabilidad 24/7 sin aumentar infraestructura.
- Reemplacé procesamiento secuencial por pipelines asíncronos en los ETLs, reduciendo tiempos de ejecución de horas a minutos sin añadir nodos al cluster.

Globant (Cliente: C.H. Robinson) Remoto

2022 - 2023

Software Engineer

Mantenimiento y optimización de sistemas actuales. Resolución de tickets de aplicación CPTS y servicio Microfocals. Ejecución de casos de prueba. Mejora del código base. Revisión de PRs del equipo para garantizar calidad del código fuente.

- Mejoré el rendimiento del servicio Microfocals reduciendo latencia en 60%.
- Identifiqué y corregí 15 vulnerabilidades de seguridad en el código base.
- Reduje la deuda técnica del proyecto en un 30% mediante refactoring.

Globant (Cliente: C.H. Robinson) Remoto

2022 - 2022

Software Engineer

Diseño de Plataforma ML con el equipo. Soporte en integraciones ML con Python. Creación de templates para DAGs en Airflow. Soporte en problemas de Kubernetes y Azure ML. Resolución de tickets de aplicación CPTS y servicio Microfocals. Revisión de PRs.

- Resolví problemas críticos de Kubernetes reduciendo downtime en 80%.
- Implementé pipelines de datos con Apache Beam procesando 500GB diarios.
- Documenté arquitectura ML adoptada como estándar para nuevos proyectos.

Globant (Cliente: SoFi) Remoto

2022 - 2022

Software Engineer

Mantenimiento y optimización de sistemas actuales. Resolución de tickets de aplicaciones de servicio y binarios. Mejora del rendimiento del proceso ETL. Creación de casos de prueba para cada HU asignada. Revisión de PRs.

- Optimicé los procesos core para que sean 30% más rápidos usando threading.
- Migré módulos core de Python 2 a Python 3.
- Reduje consumo de memoria de procesos batch en 50%.

Software Engineer

Mantenimiento y optimización de sistemas actuales. Resolución de tickets de aplicación monolítica. Creación de casos de prueba para cada HU. Aumento de cobertura de tests a más del 90%. Revisión de PRs.

- Aumenté cobertura de tests del 55% al 92% en aplicación Django.
- Resolví 60+ tickets de bugs en aplicación monolítica de alto tráfico.
- Implementé CI/CD con GitLab reduciendo tiempo de deploy de 1 hora a 10 min.
- Documenté 20+ endpoints API para uso del equipo frontend.

El Pedregal Remoto

2020 - 2021

Arquitecto de Soluciones de Software

Diseño de arquitectura de APIs y Frontends. Definición de tecnologías, patrones de diseño y frameworks para optimizar tiempo/costo/rendimiento. Revisiones y optimizaciones de código para cumplimiento de estándares. Desarrollo de estándares de arquitectura y DevOps. Gestión de framework CI/CD. Documentación de diseños de arquitectura con TOGAF y ArchiMate. Definición de paradigmas de programación (funcional, OOP, reactiva, eventos). Modelos de integración Cloud, Contenedores y Orquestación.

- Definí estándares de arquitectura de software adoptados por todos los equipos de desarrollo.
- Implementé framework DevOps y CI/CD que redujo tiempo de deploy en 80%.
- Diseñé arquitectura API REST escalable a 10K+ requests/minuto.
- Documenté arquitecturas empresariales usando TOGAF y ArchiMate.
- Migré sistemas monolíticos a microservicios con Flask y FastAPI.
- Propuse e implementé tecnologías emergentes que optimizaron procesos de negocio.

El Pedregal

2019 - 2020

Analista DevOps - Fullstack Developer

Desarrollo de aplicaciones Python/Django/Flask. Frontend con ReactJS (Hooks, Redux). Aplicaciones móviles híbridas con React Native. Desarrollo concurrente y asíncrono con threading, multiprocessing y asyncio. Optimización de aplicaciones para alto rendimiento y disponibilidad. Automatización de despliegues con enfoque DevOps. Dockerización de proyectos. Monitoreo de procesos.

- Optimicé procesos que demoraban días a solo minutos utilizando Golang.
- Implementé sistema de monitoreo con Icingav2 bajo enfoque DevOps.
- Desarrollé aplicaciones concurrentes con asyncio mejorando rendimiento 5x.
- Dockericé aplicaciones y establecí pipelines CI/CD cuando era una tecnología emergente.
- Migré 8 bases de datos entre PostgreSQL, MySQL y MongoDB sin downtime.
- Creé sistema de integración con Celery procesando 50K+ tareas diarias.

Desarrollador Python

Desarrollo de APIs Python para integración con sistemas existentes. Automatización de procesos BU Cloud con Python y Django bajo continuous delivery. Automatización y orquestación con Ansible, Ansible Tower y AWX. Despliegue de pipelines con Jenkins y containerización con Docker. Promoción del framework DevOps. Liderazgo del proyecto Atlas Inventory Cloud para Visanet. Desarrollo de componentes y librerías en Python, Perl, Bash y PowerShell. Desarrollo frontend con ReactJS. Integración de clouds AWS, Azure y GCP.

- Lideré proyecto Atlas Inventory Cloud para Visanet entregado en tiempo récord.
- Desarrollé 15 APIs REST integrando sistemas legacy con plataformas modernas.
- Automaticé 30+ procesos de BU Cloud reduciendo tiempo manual en 70%.
- Implementé 20 playbooks Ansible para orquestación de infraestructura.
- Creé pipelines Jenkins para 8 aplicaciones con despliegue automatizado.
- Integré servicios de AWS, Azure y GCP en arquitectura multi-cloud.

San Miguel Industrias PET

2015 - 2019

Analista de Infraestructura y Servicios TI

Gestión de infraestructura TIC de la corporación. Liderazgo de proyectos de innovación TI. Administración de servidores Windows Server 2008/2012 y Linux CentOS/SUSE. Administración de servidores AIX (SAP, BW, BO, BI). Administración Office365. Control de plataformas de seguridad TI (Fortinet, Kaspersky, Watchguard). Monitoreo con Icinga y Grafana. Administración System Center. Gestión de redes Cisco y Motorola. Backups con Tivoli IBM. Virtualización Hyper-V y VMware. Administración BD SQL Server, Oracle y PostgreSQL. Desarrollo de reportes con PowerBI. Scripting con Ansible, Python, Perl, C++, PowerShell, Batch y Bash. Desarrollo Django y SPAs con jQuery y Vue.js. Responsable de DataCenter. Investigación de mejoras. Viajes internacionales para despliegues TI.

- Gestioné infraestructura TI de corporación multinacional con presencia en 5 países.
- Automaticé 50+ tareas de administración con scripts Python y Ansible.
- Implementé monitoreo con Icinga y Grafana alcanzando 99.9% de uptime.
- Desarrollé 10 aplicaciones web con Django integrando SAP y sistemas legacy.
- Lideré despliegues de infraestructura TI en Colombia, Ecuador y Chile.
- Migré 200+ usuarios a Office365 sin interrupción de servicio.

Educación**Universidad Peruana de Ciencias Aplicadas**

2014 - 2018

Licenciatura in Ingeniería de Sistemas

Instituto Privado Tecnológico Cibertec

2010 - 2013

Técnico in Redes y Comunicaciones

Moscow Institute of Physics and Technology (MIPT)

2020 - 2020

Curso in Desarrollo de servicios web en Go

University of California, Irvine - Division of Continuing Education

2019 - 2020

Specialized Program in Programming with Google Go

Cisco Networking Academy

2019 - 2020

Certificación in PCAP - Programming Essentials in Python

Habilidades

LangGraph (Multi-Agent)

RAG

Azure OpenAI

Vector Databases

Embeddings & Chunking

Prompt Engineering

Semantic Kernel Concepts

High Performance

FastAPI

Microservicios

Clean Architecture

SDD

SOLID Principles

AsyncIO & Coroutines

Memory Management

Multiprocessing / Threading

Profiling (cProfile, py-spy, memray)

CI/CD

Harness

Terraform

Airflow

PostgreSQL

Redis

MongoDB

BigQuery

SQLAlchemy

Python (Experto)

Go (Avanzado)

Javascript (Avanzado)

SQL (Intermedio)

Flask

Django

React

Vue.js

Tailwind CSS

Docker (Avanzado)

Kubernetes (Avanzado)

GCP (Intermedio)

Azure

AWS

JWT

OAuth

Proyectos

Yondu

Plataforma de IA Generativa que unifica múltiples LLMs mediante API única. 24K+ req/s non-blocking, RAG vectorial y orquestación de agentes.

FastAPI

LangGraph

Azure OpenAI

LiteLLM

Kenobi

Sistema RAG empresarial para información privada. Integra con Yondu, LangGraph y bases de datos vectoriales.

RAG

ChromaDB

LangGraph

FastAPI

Fausto

Sistema IA para resolución automática de incidentes de red. Aprende de analistas y resuelve patrones conocidos.

Python

Flask

TensorFlow

Vue.js

Mercury

Sincronización de datos SAP a PostgreSQL con Golang goroutines para alto rendimiento.

Golang

PostgreSQL

SAP Integration

Engrafi ↗

Librería async de formularios para FastAPI. CSRF, rate limiting, emails y compliance GDPR.

FastAPI

Async

Security

Kivotum ↗

Gestor de medios self-hosted con FastAPI y Vue.js para organizar archivos multimedia.

FastAPI

Vue.js

Media

Titan ↗

Plataforma de autenticación FastAPI. JWT, OAuth2, RBAC y audit logging con SQLAlchemy async.

FastAPI

JWT

OAuth2

RBAC

Sthenos ↗

Load testing de alto rendimiento en Go con scripting Starlark y métricas detalladas.

Golang

Load Testing

Performance

Idiomas

Español (Nativo - C2)

Inglés (Intermedio - B2+)